

# Programación Dinámica Dual Estocástica aplicado a modelos de despacho hidrotérmico

Janice Escobedo  
Asesor: Ernesto Oré Albornoz

Universidad Nacional de Ingeniería



Agosto 25, 2023

# Tabla de contenidos

- 1 Motivación
- 2 Despacho térmico
- 3 Programación Dinámica
- 4 Programación Dinámica Dual
- 5 Programación Estocástica
- 6 SDDP



# Tabla de contenidos

- 1 Motivación
- 2 Despacho térmico
- 3 Programación Dinámica
- 4 Programación Dinámica Dual
- 5 Programación Estocástica
- 6 SDDP

# Despacho térmico

## Primer modelo de Despacho Térmico

$$\begin{aligned}
 z = \min_{g_1, \dots, g_I} & \sum_{i=1}^I c_i g_i \\
 \text{s.a.} & \sum_{i=1}^I g_i \geq d \\
 & 0 \leq g_i \leq \bar{g}_i \quad i = 1, \dots, I
 \end{aligned} \tag{1}$$

donde

**Parámetros:**

- $I$  cantidad de generadores
- $c_i$  costo unitario de operación del  $i$ -ésimo generador
- $\bar{g}_i$  capacidad del  $i$ -ésimo generador
- $d$  demanda del sistema

**Variables:**

- $g_i$  energía producida por el  $i$ -ésimo generador

**Observación:**

El problema es factible si y solo si  $0 \leq \sum_{i=1}^I \bar{g}_i - d$

## Método de Baleriaux

1. Ordenar los costos de manera ascendente, además ordenar las generadoras por los índices ascendentes.
2. Calcular la energía no suplida considerando las primeras  $i$  generadoras

$$w_i = \max\{0, d - \sum_{n=1}^i \bar{g}_n\} \quad , i = 1, \dots, I$$

3. Calcular la energía producida por cada generador

$$g_i^* = w_{i-1} - w_i \quad , i = 1, \dots, I$$

4. Calcular el costo operativo

$$z = \sum_{i=1}^I c_i g_i^*$$

**Observación** Si  $w_i = 0$  para algún  $i \in \{1, \dots, I\}$  entonces  $w_j = 0, \forall j > i$ .

### Proposición

El Método de Baleriaux es equivalente a aplicar el Algoritmo Simplex del Dual para el Modelo 1

## Proposición

Si el modelo 1 tiene solución, será única sí y solo sí existen al menos dos costos  $c_i$  y  $c_j$  iguales con  $i \neq j$

Para evitar infactibilidad al primer modelo se añade una perturbación  $\delta$  a la ecuación de demanda.

$$\begin{aligned} z = \min & \sum_{i=1}^I c_i g_i + M \cdot \delta \\ \text{s.a.} & \sum_{i=1}^I g_i + \delta = d \\ & 0 \leq g_i \leq \bar{g}_i \quad i = 1, \dots, I \\ & \delta \geq 0 \end{aligned} \tag{2}$$

## Proposición

Si el modelo 1 es factible y  $\max\{c_i, i = 1, \dots, I\} < M$  los problemas 1 y 2 tienen mismo valor optimal.

# Tabla de contenidos

- 1 Motivación
- 2 Despacho térmico
- 3 Programación Dinámica**
- 4 Programación Dinámica Dual
- 5 Programación Estocástica
- 6 SDDP



# Programación Dinámica

El modelo dinámico a optimizar tiene la estructura siguiente

$$\begin{aligned}
 \min_{d_1, \dots, d_{T-1}} \quad & \sum_{i=1}^{T-1} f_i(s_i, d_i) + f_T(s_T) \\
 \text{s.a.} \quad & s_{i+1} = t_i(s_i, d_i) \quad \forall i \in \{1, \dots, T-1\} \\
 & d_i \in D_i(s_i), s_{i+1} \in S_{i+1} \quad \forall i \in \{1, \dots, T-1\}
 \end{aligned}$$

## Principio de Optimalidad

Una política óptima tiene la propiedad de que cualquiera que sea el estado inicial y la decisión inicial, las decisiones restantes deben constituir una política óptima con respecto al estado resultante de la primera decisión.

# Funciones de Bellman

Entonces se pueden definir las funciones de Bellman.

$$v_T(s_T) = \min f_T(d_T, s_T)$$

$$s.a. d_T \in D_T$$

Para  $k_0 \in \{1, \dots, T-1\}$

$$v_{k_0}(s) = \min_{(u_{k_0}, u_{k_0+1}, \dots, u_{T-1})} \sum_{k=k_0}^{T-1} f_n(d_n, s_n) + f_T(s_T)$$

$$s_{k_0} = s, s_{k+1} = t_k(x_k, d_k), \quad \forall k \in \{k_0, \dots, T-1\}$$

$$d_k \in D_k(s_k), \quad \forall k \in \{k_0, \dots, T-1\}$$

Se desprende una técnica inductiva hacia atrás (también llamado “backward induction”).


$$v_n(s_n) = \min_{d_n} \{f_n(d_n, s_n) + v_{n+1}(s_{n+1})\} \tag{3}$$

$$s.a. s_{n+1} = t_n(s_n, d_n)$$


$$d_n \in D_n(s_n), s_{n+1} \in S_{n+1}$$

# Aplicación al Despacho Hidrotérmico

## Planeamiento y arquitectura



(a) Toma de decisiones para el despacho hidrotérmico



(b) Función de Costo Inmediato y Futuro

# Aplicación al despacho hidrotérmico

El modelo hidrotérmico se formula como sigue

$$z^* = \min_{u_t, s_t} \sum_{t=1}^T c_t(u_t) \quad (4)$$

$$\text{s.t. } v_{t+1} = v_t - u_t - s_t + a_t, \quad t \in \{1, 2, \dots, T-1\}$$

$$0 \leq v_{t+1} \leq \bar{v}, \quad t \in \{1, 2, \dots, T-1\}$$

$$0 \leq u_t \leq \bar{u}, 0 \leq s_t \quad \forall t \in \{1, 2, \dots, T\}$$

con  $c_t(u_t)$  siendo el costo de complementación térmica y definido por

$$c_t(u_t) = \min_{g_t(1), \dots, g_t(J), \delta} \sum_{j=1}^J c_t(j) \cdot g_t(j) + c_\delta \cdot \delta$$

$$\text{s.a. } \sum_{j=1}^J g_t(j) + \delta + \rho u_t = d_t, \quad t = 1, \dots, T$$

$$0 \leq g_t(j) \leq \bar{g}(j), \quad j = 1, \dots, J, \quad t = 1, \dots, T$$

$$0 \leq \delta$$

Considerando a  $\{v_t^1, v_t^2, \dots, v_t^M\}$  los almacenamientos para la etapa  $t$ , la ecuación de recursión de Bellman es

$$\alpha_t(v_t^m) = \min_{u_t, s_t} c_t(u_t) + \alpha_{t+1}(v_{t+1}) \quad (5)$$


$$s.a. \quad v_{t+1} = v_t^m - u_t - s_t + a_t$$

$$0 \leq v_{t+1} \leq \bar{v}$$

$$0 \leq u_t \leq \bar{u}$$

$$s_t \geq 0$$

La función  $\alpha_t(v_t)$  se halla interpolando los valores  $\{\alpha_t(v_t^m), m = 1, \dots, M\}$



**Figura:** Formación de Funciones de Costo Futuro

# Ejemplo

Consideremos un sistema de un planeamiento de 4 meses compuesto por una planta hidráulica y dos plantas térmicas cuyas características se muestran en las tablas.

Almacenamiento máximo ( $hm^3$ )	Almacenamiento mínimo ( $hm^3$ )	Turninado máximo $\bar{u}$ ( $hm^3$ )	Coefficiente de producción ( $MW-mes/hm^3$ )
120	20	50	0.9

Tabla: Características de la planta hidraulica

Térmica	Máxima generación ( $MW$ )	Costo de operación ( $\$/MW - mes$ )
$T_1$	20	10
$T_2$	25	20

Tabla: Características de las plantas térmicas

La demanda es de  $45MW-mes$  para todas las etapas y la penalidad por fallo al suplir la demanda, que es representada por una planta térmica artificial, es de  $1000\$/MW-mes$ . Además, los caudales para cada etapa son 15, 18, 17, 14  $hm^3/mes$ . En el embalse se considerarán 5 niveles los cuales son 0%, 25%, 50%, 75%, 100%.

Almacenamiento (%)	$v_1$	0	25	50	75	100
Caudal ( $hm^3$ )	$a_1$	15	15	15	15	15
Decisión Optimal	$v_2$	0	12.2	37.2	62.2	75
	$u_2$	15	27.8	27.8	27.8	40
	$s_1$	0	0	0	0	0
	$g_1(1)$	20	20	20	20	9
	$g_1(2)$	11.5	0	0	0	0
	$\delta$	0	0	0	0	0
Costo inmediato (\$)		430.0	200.0	200.0	200.0	90.0
Costo futuro (\$)		1218.0	1015.104	645.036	359.686	234.0
Costo optimal (\$)		1648.0	1215.104	845.036	559.686	324.0

Figura: Resultados etapa 1




Figura: Función de costo futuro en la etapa 1



# Tabla de contenidos

- 1 Motivación
- 2 Despacho térmico
- 3 Programación Dinámica
- 4 Programación Dinámica Dual**
- 5 Programación Estocástica
- 6 SDDP

# Descomposición de Benders

Consideremos el problema

$$\begin{aligned}
 & \underset{x,y}{\text{minimize}} && f(x) + d^t y && (6) \\
 & \text{s.a.} && F(x) + By \geq e && (P) \\
 & && x \in \mathcal{X} \\
 & && x \geq 0, y \geq 0
 \end{aligned}$$

Sea  $\alpha : \mathbb{R}^n \rightarrow \overline{\mathbb{R}}$ , conocida como la función valor, definida como

$$\begin{aligned}
 \alpha(x) &= \min_y d^t y && (7) \\
 & \text{s.a.} && By \geq e - F(x) && (Sub) \\
 & && y \geq 0
 \end{aligned}$$

donde  $\text{dom}(\alpha) = \{x : \exists y, F(x) + By \geq e, y \geq 0\}$ .

## Proposición

El problema (P) es equivalente a

$$\begin{aligned}
 \min \quad & f(x) + \alpha(x) \\
 \text{s.a.} \quad & x \in \mathcal{X} \quad (\bar{P}) \\
 & x \geq 0
 \end{aligned}$$

En particular  $(x^*, y^*) \in \text{sol}(P)$  si y solo si  $x^* \in \text{sol}(\bar{P})$  y  $y^* \in \text{sol}(\text{Sub})$

## Proposición

Cuando  $F(x)$  sea convexa y  $\text{dom}(\alpha)$  es no vacío entonces la función  $\alpha$  es convexa.

Consideremos el dual del Subproblema

$$\begin{aligned}
 \tilde{\alpha}(x) = \max_{\lambda} \quad & (e - F(x))^t \lambda \\
 \text{s.a.} \quad & B^t \lambda \leq d \quad (D) \\
 & \lambda \geq 0
 \end{aligned}$$

Denotemos al conjunto factible de (D) por  $S = \{\lambda, B^t \lambda \leq d, \lambda \geq 0\}$

Asumiremos a partir de ahora que  $S \neq \emptyset$ . Además podemos ver que  $S$  es un poliedro, entonces

$$S = \text{conv}\{\lambda_1, \dots, \lambda_r\} + \text{cone}\{d_1, \dots, d_s\}$$

### Proposición

Se cumple que  $\alpha(x) = \sigma_S(e - F(x))$ , siendo

$$\sigma_S(\bar{v}) = \begin{cases} \max\{\lambda^t \bar{v} / i = 1, \dots, r\} & , \text{ si } \bar{v} \in K \\ +\infty & , \text{ si } \bar{v} \notin K \end{cases} \quad (8)$$

con  $K = \{\bar{v} / d^t \bar{v} \geq 0 \ \forall i = 1, \dots, s\}$

Así se puede concluir que si  $F(x)$  es lineal entonces  $\alpha(x)$  es lineal por partes y convexa.

El problema maestro se reescribe como

$$\begin{aligned}
 \min_{x, \alpha} \quad & c^t x + \alpha \\
 \text{s.a.} \quad & x \in \mathcal{X} \\
 & \alpha \geq (e - F(x))^t \lambda^i \quad i = 1, \dots, r \\
 & 0 \geq (e - F(x))^t d^j \quad j = 1, \dots, s \\
 & x \geq 0
 \end{aligned} \tag{9}$$

Considerando  $U' \subset \{\lambda^1, \dots, \lambda^r\}$  y  $V' \subset \{d^1, \dots, d^s\}$ .

$$\begin{aligned}
 \min_{x, \alpha} \quad & c^t x + \alpha \\
 \text{s.a.} \quad & x \in \mathcal{X}, x \geq 0 \\
 & \alpha \geq (e - F(x))^t \lambda^i \quad \lambda^i \in U' \\
 & 0 \geq (e - F(x))^t d^j \quad d^j \in V'
 \end{aligned} \tag{10}$$

## Teorema

Sea  $(\bar{x}, \bar{\alpha})$  una solución optimal del Problema Maestro restricto. Si  $\lambda^*$  es el vértice optimal de la solución y  $z^*$  el valor optimal del Dual  $\alpha(x)$  entonces

- (i) Si  $\bar{\alpha} > z^*$  entonces  $\lambda^*$  es un nuevo vértice generado
- (ii) Si  $\bar{\alpha} = z^*$ , entonces  $(\bar{x}, \bar{\alpha})$  es una solución optimal del Problema Maestro.

Si  $\alpha(\bar{x})$  es no acotado entonces una nueva dirección extrema es dada.

## Convergencia

El Subproblema dual tiene finitos puntos extremos y direcciones extremas por lo que el algoritmo termina en un número finito de iteraciones. Además la cota inferior es monótonamente creciente.

## Algorithm .

**Paso 1:** Hacemos  $k = 1$ , fijamos  $z_l = 0$  y  $z_u = \infty$ .

**Paso 2:** Resolver el Problema Maestro fijando  $y = 0$ . Si la solución es infactible, **PARAR**; caso contrario, almacenamos  $x = x^k$

**Paso 3:** Resolvemos el Subproblema

**Paso 3.1:** Si tiene solución infactible entonces el problema principal es infactible o no acotado, **PARAR**.

**Paso 3.2:** Si la solución del subproblema en la iteración  $k$  con la variable dual  $\lambda^*$  y con valor optimal  $z^*$ .

**Paso 3.2.1:** Si  $\bar{\alpha} > z^*$ . Actualizar Problema Maestro añadiendo una restricción, asociado a un corte optimal, correspondiente al vertice  $\lambda^*$

$$\alpha \geq (e - Ax)^t \lambda^i$$

e ir al **Paso 5**

**Paso 3.2.2:** Si  $\bar{\alpha} = z^*$ , **PARAR**

**Paso 3.3:** Si el problema es no acotado, actualizamos Problema Maestro introduciendo el corte factible asociado a una dirección extrema

$$(e - Ax)^t \lambda^q \leq 0, \quad q \in V$$

e ir al Paso 5.

**Paso 4:** Convergencia (brecha entre Problema Maestro y Subproblema)

Si  $\bar{\alpha} - z^* \leq \varepsilon$ , **PARAR**, en otro caso continuar con **Paso 5**.

**Paso 5:** Actualizar iteración  $k \leftarrow k + 1$  y resolver el Problema Maestro Restringido. Si la solución es infactible el algoritmo se detiene; caso contrario, almacenamos el valor optimo es  $(x^k, \bar{\alpha})$  y volvemos al **Paso 3**

# Tabla de contenidos

- 1 Motivación
- 2 Despacho térmico
- 3 Programación Dinámica
- 4 Programación Dinámica Dual
- 5 Programación Estocástica**
- 6 SDDP



# Programación Estocástica

Un problema estocástico de una etapa viene dado como sigue:

$$\min_{x \in X} \{f(x) := \mathbb{E}_{\mathbb{P}} F(x, \xi)\}$$

Y su modelo determinístico asociado es como sigue

$$\begin{aligned} \min_x \quad & \sum_{i=1}^S p_{\xi_s} \cdot F(x, \xi_s) \\ \text{s.a. } & x \in \mathcal{X}(\xi_s) \quad \forall s = 1, \dots, S \end{aligned}$$

donde  $p_{\xi_s} = \mathbb{P}(\xi = \xi_s)$

# Aplicación al despacho Térmico

$$z = \min \sum_{k=1}^K p_k \sum_{i=1}^J q_j \left( \sum_{i=1}^I c_i g_{ijk} + c_{\delta} \cdot \delta_{jk} \right) \quad (11)$$

$$s.a. \sum_{i=1}^I g_{ijk} + \delta_{jk} = d_j \quad j = 1, \dots, J, \quad k = 1, \dots, K \quad (12)$$

$$0 \leq g_{ijk} \leq \bar{g}_{ik} \quad i = 1, \dots, I \quad j = 1, \dots, J, \quad k = 1, \dots, K \quad (13)$$

$$\delta_{jk} \geq 0$$

donde

## Variables:

$g_{ijk}$  energía producida por el  $i$ -ésimo generador en el nivel de demanda  $j$ , escenario  $k$

$\delta_{jk}$  energía no satisfecha del nivel  $j$ , escenario  $k$  debido a la insuficiencia de generación

# Aplicación al despacho Hidrotérmico

$$z = \min \sum_{k=1}^K p_k \sum_{j=1}^J q_j \left( \sum_{i=1}^I c_i g_{ijk} + c_\delta \cdot \delta_{jk} \right) \quad (14)$$

$$\text{s.a.} \sum_{i=1}^I g_{ijk} + h_{jk} + \delta_{jk} = d_j \quad j = 1, \dots, J, \quad k = 1, \dots, K$$

$$0 \leq g_{ijk} \leq \bar{g}_{ik} \quad i = 1, \dots, I \quad j = 1, \dots, J, \quad k = 1, \dots, K$$

$$0 \leq h_{jk} \leq \bar{h}, \quad j = 1, \dots, J, \quad k = 1, \dots, K$$

$$\sum_{j=1}^J q_j h_{jk} \leq E, \quad k = 1, \dots, K$$

$$\delta_{jk} \geq 0 \quad j = 1, \dots, J, \quad k = 1, \dots, K$$

donde

$g_{ijk}$  energía producida por el  $i$ -ésimo generador en el nivel de demanda  $j$ , escenario  $k$

$\delta_{jk}$  energía no satisfechan del nivel  $j$ , escenario  $k$  debido a la insuficiencia de generación

$h_{jk}$  generación de la hidroeléctrica en el nivel de demanda  $j$ , escenario  $k$

# Problemas de multietapa

Un problema de programación estocástica con  $T$  etapas puede ser escrita como sigue.

$$\begin{aligned}
 \min_{x_1 \in X_1} f_1(x_1) + \mathbb{E}_{\xi_2 | \xi_{[1]}} \left[ \min_{x_2 \in X_2(x_1, \xi_2)} f_2(x_2, \xi_2) + \mathbb{E}_{\xi_3 | \xi_{[2]}} \left[ \min_{x_3 \in X_3(x_2, \xi_3)} f_3(x_3, \xi_3) + \dots \right. \right. \\
 \left. \left. + \mathbb{E}_{\xi_T | \xi_{[T-1]}} \left[ \min_{x_T \in X_T(x_{T-1}, \xi_T)} f_T(x_T, \xi_T) \right] \right] \right]
 \end{aligned} \tag{15}$$

donde  $\mathbb{E}_{X|Y}$  representa la esperanza condicional de  $X$  dado  $Y$ . Además, el proceso de decisiones

$$x_1 \longrightarrow \xi_2 \longrightarrow x_2 \longrightarrow \xi_3 \longrightarrow \dots \longrightarrow \xi_T \longrightarrow x_T \tag{16}$$

# Programación Estocástica Multietapa

El problema lineal de un programa estocástico con  $T$  etapas se puede escribir como sigue

$$\begin{aligned}
v^* = \min_{x_1} \quad & c_1^T x_1 + \mathbb{E}_{\xi_2|\xi_{[1]}} \left[ \min_{x_2} c_2(\xi_2)^T x_2(\xi_2) + \dots \right. \\
& \left. + \mathbb{E}_{\xi_T|\xi_{[T-1]}} \left[ \min_{x_T} c_T(\xi_T)^T x_T(\xi_T) \right] \right] \\
s.a. \quad & W_1 x_1 = h_1 \\
& A_1(\xi_2)x_1 + W_2(\xi_2)x_2(\xi_2) = h_2(\xi_2) \\
& A_2(\xi_3)x_2(\xi_2) + W_3(\xi_3)x_3(\xi_3) = h_3(\xi_3) \\
& \vdots \qquad \qquad \qquad \vdots \qquad \qquad \qquad \ddots \\
& A_{T-1}(\xi_T)x_{T-1}(\xi_{T-1}) + W_T(\xi_T)x_T(\xi_T) = h_T(\xi_T) \\
& x_1, x_2(\xi_2), \dots, x_T(\xi) \geq 0
\end{aligned} \tag{P}$$

los datos son  $\xi_t = (c_t, T_1, W_t, h_t)$

Las decisiones de recurso  $x_t(\xi_{[t]})$  puede ser tomada con conocimiento de la historia del proceso de datos de la etapa 1 hasta la  $t$ , que se denota por  $\xi_{[t]} = (\xi_1, \dots, \xi_t)$ . Usando las ecuaciones de Bellman el problema se reformula como

$$Q_t(x_{t-1}, \xi_{[t-1]}, \xi_t) = \begin{cases} \min_{x_t} & c_t^T(\xi_t)x_t + Q_{t+1}(x_t, \xi_{[t]}) \\ \text{s.a.} & W_t(\xi_t)x_t = h_t(\xi_t) - A_{t-1}(\xi_t)x_{t-1} \\ & x_t \geq 0 \end{cases} \quad (17)$$

donde

$$Q_{t+1}(x_t, \xi_{[t]}) := \mathbb{E}_{\xi_{t+1}|\xi_{[t]}} [Q_{t+1}(x_t, \xi_{[t]}, \xi_{t+1})] \quad (18)$$

con  $Q_{T+1}(x_T, \xi_{[T]}) \equiv 0$ . A  $Q_t(\cdot, \cdot)$  se le llama función valor y a  $Q_t(\cdot, \cdot)$  se le llama función valor esperada, función de costo futuro o función de recurso. Para la primera etapa obtenemos el valor óptimo

$$v^* = \begin{cases} \min_{x_1} & c_1^T x_1 + Q_1(x_1, \xi_{[1]}) \\ \text{s.a.} & W_1 x_1 = h_1 \\ & x_1 \geq 0 \end{cases} \quad (19)$$

Para asegurar la existencia de soluciones factibles en el problema de optimización

### Suposición 1

El problema  $(P)$  tiene recurso relativamente completo; es decir, para cualquier  $x_{t-1}$  factible para la etapa  $t - 1$ , el subproblema de la etapa  $t$  es factible para cada realización de  $\xi_t$  de forma casi segura.

### Suposición 2

Existe un número finito de realizaciones de  $\xi_t$  para cada  $t = 2, \dots, T$

### Suposición 3

Las distribuciones de probabilidad  $F_\xi$  del proceso  $(\xi)_{t=1}^T$  es conocida.

### Suposición 4

Las distribuciones de probabilidad  $F_\xi$  del proceso  $(\xi)_{t=1}^T$  no es dependiente de la política escogida.

# Aplicación al despacho Hidrotérmico

El modelo hidrotérmico se formula como sigue

$$z^* = \min_{u_t, s_t} \mathbb{E} [c_1(u_1) + \mathbb{E} [c_2(u_2) + \dots + \mathbb{E} [c_T(u_T)]]] \quad (20)$$

$$\begin{aligned} \text{s.t. } v_{t+1} &= v_t - u_t - s_t + a_t, \quad t \in \{1, 2, \dots, T\} \\ 0 &\leq v_{t+1} \leq \bar{v} \quad \forall t \in \{1, 2, \dots, T\} \\ 0 &\leq u_t \leq \bar{u}, \quad 0 \leq s_t \quad \forall t \in \{1, 2, \dots, T\} \end{aligned} \quad (21)$$

con  $c_t(u_t)$  el costo de complementación térmica definido como

$$\begin{aligned} c_t(u_t) &= \min_{g_t(1), \dots, g_t(J), \delta} \sum_{j=1}^J c_t(j) \cdot g_t(j) + c_\delta \cdot \delta \\ \text{s.a. } \sum_{j=1}^J g_t(j) + \delta + \rho u_t &= d_t, \quad t = 1, \dots, T \\ g_t(j) &\leq \bar{g}(j), \quad j = 1, \dots, J, \quad t = 1, \dots, T \end{aligned}$$



Entonces el problema se puede representar como

$$\begin{aligned}
 \alpha_t^k(v_t^m) &= \min_{u_{t,s}} c_t(u_{t,s}) + \alpha_{t+1}(v_{t+1}) \\
 \text{s.a. } v_{t+1} &= v_t^m - u_{t,s} - s_t + a_t^m \\
 0 &\leq v_{t+1} \leq \bar{v} \\
 0 &\leq u_{t,s} \leq \bar{u} \\
 s_{t,s} &\geq 0
 \end{aligned}$$

Luego calculamos los costos operativos considerando todos los escenarios de caudales

$$\alpha_t(v_t^m) = \sum_{k=1}^K p_k \cdot \alpha_t^k(v_t^m)$$

Para finalmente construir la función de costo futuro,  $\alpha_t(v_t)$ , interpolamos los valores de  $\{\alpha_t(v_t^m); m = 1, \dots, M\}$

# Ejemplo

Si se tienen los datos de las tablas 1 y 2, donde los caudales son ahora en relación a la siguiente tabla

Etapa	Escenario 1	Escenario 2	Escenario 3
1	15	20	17
2	25	18	19
3	17	13	15
4	14	12	16

Reemplazando los parámetros y usando la implementación en el Lenguaje Gams, se obtiene la función de costo para la primera etapa.

Almac. $v_2$ (%)		0			25			50			100		
Caudal ( $hm^3$ )		15	20	17	15	20	17	15	20	17	15	20	17
Decisión Optimal	$v_2$	0	0	47.2	0	0	47.2	40.2	75	68	40.2	75	68
	$u_2$	15	20	17	27.8	27.8	27.8	27.8	27.8	27.8	40	45	42
	$s_2$	0	0	0	0	0	0	0	0	0	0	0	0
	$g_1(1)$	20	20	20	20	20	20	20	20	20	9	4.5	7.2
	$g_1(2)$	11.5	7	9.7	11.5	0	0	0	0	0	0	0	0
	$\delta$	0	0	0	0	0	0	0	0	0	0	0	0
CI		430.0	340	394	430.0	200	200.0	200.0	200.0	200.0	90	45	72
CF+CI		1636.0	1546.0	1600	1203.2737	1120.3402	1170.1003	834.7389	770.6779	809.1145	318.0	273.0	300
COP (\$)		1594.0			1164.571			804.844			297.0		

Figura: Resultados etapa 1

# Resultados




Figura: Función de costo futuro en la etapa 1

# Tabla de contenidos

- 1 Motivación
- 2 Despacho térmico
- 3 Programación Dinámica
- 4 Programación Dinámica Dual
- 5 Programación Estocástica
- 6 SDDP

## Suposición 1

La incertidumbre de resolver el problema ( $P$ ) es independiente por etapas; es decir, es independiente de la historia  $\xi_{[t-1]}$  del proceso

### Pase hacia adelante

Los índices de  $k \in K$  denotan los escenarios muestreados con  $K \subset S$  y  $K \ll S$ . Los subproblemas a resolver para la iteración  $i$ , etapa  $t = 2, \dots, T$  y muestreo  $k$  se denotan

$$\underline{Q}_t^i(x_{t-1}^{ik}, \xi_t^k) = \begin{cases} \min_{x_t} & c_t^T(\xi_t^k)x_t + \underline{Q}_{t+1}^i(x_t) \\ \text{s.a.} & W_t(\xi_t^k)x_t = h_t(\xi_t^k) - A_{t-1}(\xi_t^k)x_{t-1}^{ik} \\ & x_t \geq 0 \end{cases} \quad (22)$$

# Pase hacia adelante

## Intervalo de confianza

La cota inferior es

$$\bar{v}_K^i = \frac{1}{|K|} \sum_{k \in K} \underbrace{\sum_{t=1}^T c_t^T(\xi_t^k) x_t^{ik}}_{=: v^i(\xi^k)} \quad (23)$$

Así un intervalo de confianza es

$$\left[ \bar{v}_K^i - z_{1-\alpha/2} \frac{\sigma_{\bar{v},K}^i}{\sqrt{|K|}}, \bar{v}_K^i + z_{1-\alpha/2} \frac{\sigma_{\bar{v},K}^i}{\sqrt{|K|}} \right]$$

donde  $z_{(1-\alpha/2)}$  representa el cuantil de la distribución Normal estandar, y  $(\sigma_{\bar{v},K}^i)^2 := \frac{1}{|K|-1} \sum_{k \in K} (v^i(\xi^k) - \bar{v}_K^i)^2$

# Pase hacia atrás

Para todas las soluciones prueba  $x_{t-1}^{ik}, k \in K$  los siguientes subproblemas son resueltos para todas posibles realizaciones de la etapa  $t$  (aperturas hacia atrás)  $\xi_{tj}^k \equiv \xi_{tj}, j = 1, \dots, q_t$ :

$$\underline{Q}_t^{i+1}(x_{t-1}^{ik}, \xi_{tj}) = \begin{cases} \min_{x_t} & c_t^T(\xi_{tj})x_t + \Omega_{t+1}^{i+1}(x_t) \\ \text{s.a.} & W_t(\xi_{tj})x_t = h_t(\xi_{tj}) - A_{t-1}(\xi_{tj})x_{t-1}^{ik} \\ & x_t \geq 0 \end{cases} \quad (24)$$

$$= \begin{cases} \min_{x_t, \theta_{t+1}} & c_t^T(\xi_{tj})x_t + \theta_{t+1} \\ \text{s.a.} & W_t(\xi_{tj})x_t = h_t(\xi_{tj}) - A_{t-1}(\xi_{tj})x_{t-1}^{ik} \\ & \theta_{t+1} \geq (\beta_{t+1}^r)^T x_t + \alpha_{t+1}^r, \quad r \in R_{t+1} \\ & x_t \geq 0 \end{cases} \quad (25)$$

Considerando  $\Omega_{T+1}(\cdot) \equiv 0$

Sea  $\pi_t^{ij}$  y  $\rho_t^{ijr}$ ,  $r \in R_{t+1}$  denota los vectores optimales duales de los problemas anteriores si tuviesen.

$$\beta_t := - \sum_{j=1}^{q_t} p_{tj} (\pi_t^{ij})^T A_{t-1}(\xi_{tj})$$

y

$$\alpha_t := \sum_{j=1}^{q_t} p_{tj} \left( (\pi_t^{ij})^T h_t(\xi_{tj}) + \sum_{r \in R_{t+1}} \rho_t^{ijr} \alpha_{t+1}^r \right)$$

Así, el corte es dado por

$$Q_t x_{t-1} \geq \alpha_t + \beta_t^T x_{t-1}$$

para todo  $x_{t-1}$ .



# Ejemplo

Considerando los datos del problema de Programación Estocástica Dinámica con un volumen inicial de 25, nuestro problema queda

```
# Building the subproblem for each node
function subproblem_builder(subproblem::Model, node::Int)
    # State variables: volume
    @variable(subproblem, 0 <= volume <= 100, SDDP.State, initial_value = 25)
    # Decision variables:
    @variables(subproblem, begin
        thermal_generation1 >= 0
        thermal_generation2 >= 0
        hydro_generation >= 0
        hydro_spill >= 0
    end)
    # Inflow as a random variable
    @variable(subproblem, inflow)
    P = [1 / 3, 1 / 3, 1 / 3] # probability with case occur
    Inflows = [[15.0, 20.0, 17.0], [25.0, 18.0, 19],
               [17.0, 13.0, 15.0], [14.0, 12.0, 16.0]]
    # omega is a vector of realizations
    SDDP.parameterize(subproblem, Inflows[node], P) do ω
        return JuMP.fix(inflow, ω)
    end
end
```

Figura: Construcción 1

```

# Transition function and constraints
@constraints(
    subproblem,
    begin
        # hydric balance
        volume.out == volume.in - hydro_generation - hydro_spill + inflow
        # nodal balance
        demand_constraint, 0.9 * hydro_generation + thermal_generation1 + thermal_generation2 == 45
        thermal_generation1 <= 20
        thermal_generation2 <= 25
        hydro_generation <= 50
    end
)

# Stage-objective
@stageobjective(subproblem, 10 * thermal_generation1 + 20 * thermal_generation2)
return subproblem
end subproblem_builder (generic function with 1 method)

# Construct the model
model = SDDP.LinearPolicyGraph(
    subproblem_builder,
    stages = 4,
    sense = :Min,
    lower_bound = 0.0, # we cannot incur in negative cost
    optimizer = HiGHS.Optimizer, # solver
) A policy graph with 4 nodes.

```

Figura: Construcción 2

```
# Training our policy
SDDP.train(model; iteration_limit = 20) ✓

# Get a decision rule
rule = SDDP.DecisionRule(model; node = 1) A decision rule for node 1
# rule
# Evaluating a decision rule
solution = SDDP.evaluate(
    rule;
    incoming_state = Dict{:volume => 25.0},
    noise = 50.0,
    controls_to_record = [:hydro_generation, :thermal_generation1, :thermal_generation2],
) (stage objective = 200.0, outgoing state = Dict{:volume => 47.22222222222222}, controls = Dict{:the...
```

Figura: Entrenamiento

	$c(u_1)$	$g_1(1)$	$g_1(2)$	$u_1$
Valores	200	20	0	27.8

```
# Get the outgoing volume
outgoing_volume = map(simulations[1]) do node
    return node[:volume].out
end 4-element Vector{Float64}:

thermal_generation = map(simulations[1]) do node
    return node[:thermal_generation1], node[:thermal_generation2]
end 4-element Vector{Tuple{Float64, Float64}}:
```

Figura: Resultados de la simulación

Etapa	$vol.out$	$g_t(1)$	$g_t(2)$
1	25.3	20	11.8
2	22.5	20	6.3
3	11.7	20	3.6
4	0	20	0

Con un intervalo de confianza de  
 $(1124.74 - 16.617954730734084, 1124.74 + 16.617954730734084)$   
 y una cota inferior de 1144.0

# Conclusiones

- 1 Para un despacho Térmico el método de Baleriaux y el algoritmo Simplex Dual son equivalentes.
- 2 El algoritmo de Bender resulta un algoritmo de descomposición en la cual aproxima por medio de cartas a la función valor y con información de su dual.
- 3 El algoritmo SDDP toma en cuenta independencia de la incertidumbre por etapa, aprovecha la aproximación a la media muestral y toma muestras por etapa en lugar de considerar todos los escenarios con lo cual logra reducir la dimensionalidad. Además se aproxima, con cierta confianza, a la solución para un planeamiento de  $T$  etapas mediante los cortes hallados por información de un subproblema Dual.